


Apprentissage automatique pour l'évaluation et la prévision des performances des produits en ligne

Présenté par:

Frank ONANA TSANGA
Cabrel SADJUE KWENDJI
Naouel YOUSFI
Thierry YOUM ESEMTSOU

Enseignant: Mohand Said Allili

Session: Hiver 2026



Plan de la présentation



PROBLÉMATIQUE.



MÉTHODOLOGIE.



EXPÉRIMENTATION



CONCLUSIONS.




Problématique

Dans un environnement de commerce électronique de plus en plus compétitif, **comment analyser et modéliser la performance des produits** afin de mieux comprendre et anticiper les comportements d'achat des consommateurs ?

Objectif général

Analyser et modéliser les performances des produits dans un contexte e-commerce

Objectifs spécifiques

- Développer et comparer divers modèles de machine learning pour prédire la performance commerciale
 - Identifier les facteurs les plus influents sur la satisfaction client
- 

Jeu de données

Jeu de données synthétiques mais réaliste issu de Kaggle, simulant un environnement de commerce électronique

Ce dataset comprend 2 000 enregistrements et 09 variables

- le prix du produit
- le taux de remise
- la note moyenne des clients
- le nombre d'avis
- la disponibilité en stock
- le délai de livraison
- le taux de retour
- l'identifiant de catégorie



Méthodologie


✓ **Prétraitement et analyse exploratoire**

- imputation des valeurs manquantes : médiane pour les variables quantitatives, mode pour la variable qualitative (disponibilité de stock)
- Identification des valeurs aberrantes et standardisation des variables quantitatives.
- Split du jeu de données 80% entraînement et 20% test.

✓ **Définition de la performance d'un article:** analyse intuitive, implémentation des algorithmes non supervisés (K-means, DBSCAN et TSNE) pour le regroupement des articles en classes homogènes

✓ **Prédire la performance commerciale et identifier les facteurs les plus influents sur la satisfaction client:** implémentation des algorithmes KNN, Naïf Bayes, SVM, arbre de décision, réseau de neurones et forêts aléatoires pour

Choix de la variable Cible: Première tentative



Performant = 1 **Product_Rating** $\geq$ mean(Product_Rating) et **Return_Rate** $\leq$ mean(Return_Rate)
0 Sinon

Implémentation des modèles de classification

En gardant les variables

(Product_Rating, Return_Rate)

	Modèle	Accuracy	Precision (weighted)	Recall (weighted)	F1-Score (weighted)
3	Decision Tree	1.000000	1.000000	1.000000	1.000000
5	Random Forest	1.000000	1.000000	1.000000	1.000000
4	Neural Network	0.986842	0.987092	0.986842	0.986894
2	SVM	0.926316	0.938057	0.926316	0.928226
1	Naive Bayes	0.886842	0.897900	0.886842	0.889483
6	Logistic Regression	0.868421	0.885896	0.868421	0.872251
0	KNN	0.857895	0.889889	0.857895	0.863292

Excluant les variables


(Product_Rating, Return_Rate)

	Modèle	Accuracy	Precision (weighted)	Recall (weighted)	F1-Score (weighted)
5	Random Forest	0.636842	0.575763	0.636842	0.596589
4	Neural Network	0.597368	0.631861	0.597368	0.610524
2	SVM	0.534211	0.599204	0.534211	0.554894
0	KNN	0.526316	0.599168	0.526316	0.547994
3	Decision Tree	0.523684	0.613491	0.523684	0.545745
6	Logistic Regression	0.502632	0.577155	0.502632	0.525461
1	Naive Bayes	0.357895	0.561441	0.357895	0.326235



Data Leakage

Choix de la variable Cible: Deuxième tentative



- **Le Cluster 1 (Performance Élevée)** : C'est le groupe le mieux noté (moyenne de 3.92) avec un volume de commentaires très important (553 en moyenne), malgré un taux de retour un peu plus élevé.
- **Le Cluster 0 (Logistique Lente)** : Il regroupe des produits avec un prix plus abordable (125) mais un délai de livraison long (21 jours).
- **Le Cluster 3 (Livraison Rapide)** : Ce groupe se distingue par une livraison très rapide (9 jours en moyenne), bien qu'il ait la note moyenne la plus basse (3.45).
- **Le Cluster 2 (équilibristes)** : Un profil équilibré avec un volume de ventes plus restreint (177 produits)

Les modèles

Modèle	Hyperparamètre Clé	Valeur	Action sur l'Apprentissage
SVM	C=1.0	1.0	Anti-Overfitting : Crée une "marge souple" pour ignorer les points aberrants et privilégier une séparation large.
Arbres de decison	max_depth	5	Anti-Overfitting : Coupe l'arbre avant qu'il ne crée des règles "par cœur" sur des détails inutiles.
Reseaux de Neurones	early_stopping	TRUE	Anti-Overfitting : Arrête l'entraînement dès que le modèle commence à stagner, évitant la saturation.
	alpha	0.01	Anti-Overfitting : Force les poids des neurones à rester petits pour éviter une trop grande complexité.
Foret aleatoire	n_estimators	200	Stabilité : Réduit la variance globale en moyennant les décisions de 200 arbres différents.
	max_features	sqrt	Diversité : Force chaque arbre à être différent, ce qui renforce la robustesse de la "forêt".
KNN	n_neighbors	11	Anti-Underfitting : Un nombre impair (11) évite les égalités et lisse les frontières de décision.
	weights	distance	Précision : Donne plus d'importance aux voisins les plus proches pour mieux coller à la réalité locale.
Naive Bayes	var_smoothing	1,00E-02	Stabilité : Ajoute un "bruit" statistique pour éviter qu'une probabilité nulle ne bloque la classification.
Validation croisée	CV	5	La validation croisée permet de vérifier la stabilité et la fiabilité de tes mesures.

Les métriques

	Modèle	Accuracy	Precision (weighted)	Recall (weighted)	F1-Score (weighted)
2	SVM	0.968421	0.968653	0.968421	0.968464
3	Decision Tree	0.960526	0.961224	0.960526	0.960652
4	Neural Network	0.960526	0.961314	0.960526	0.960672
0	KNN	0.928947	0.929019	0.928947	0.928944
1	Naive Bayes	0.926316	0.932638	0.926316	0.927105
5	Random Forest	0.921053	0.924486	0.921053	0.921150


Conclusion

❑ Synthèse des résultats

- **Champion (SVM - 96,8 %)** : Offre la meilleure capacité de généralisation grâce à sa gestion optimale des marges de séparation.
- **Robustesse** : La convergence de tous les modèles vers des scores élevés ($> 0,92$) confirme que les clusters identifiés reposent sur des variables discriminantes fortes et non sur du bruit.
- **Équilibre** : Les scores de Précision et de Rappel quasi identiques garantissent une détection fiable de chaque cluster, même pour les classes initialement minoritaires.

❑ Recommandation finale

- Le modèle **SVM** est retenu pour sa précision maximale.
- Le modèle **Random Forest** pourra servir d'outil complémentaire pour expliquer les décisions métier grâce à l'importance des variables.



MERCI
POUR VOTRE AIMABLE
ATTENTION

